

Grundlagen neuronaler Netzwerke und Relevanz für CCS

Neuronale Netzwerke sind eine wesentliche Technologie im Bereich der künstlichen Intelligenz (KI), die von biologischen Gehirnen inspiriert sind. Diese Netzwerke bestehen aus einer Vielzahl von verbundenen Knotenpunkten, den sogenannten Neuronen, die in Schichten organisiert sind. Jedes Neuron empfängt Eingabewerte, verarbeitet diese mit einer Aktivierungsfunktion und gibt ein Signal weiter, das je nach Gewichtung Verbindungen zu anderen Neuronen beeinflusst. Durch iterative Anpassung der Gewichte während eines Trainingsprozesses lernen neuronale Netzwerke, Muster zu erkennen und Vorhersagen zu treffen.

Das **CCS-Modell (Cognitive Contextual Simulation)** baut auf diesen Prinzipien auf und erweitert sie um kontextuelle, emotionale und soziale Dimensionen. CCS kombiniert klassische neuronale Ansätze mit domänenspezifischen Anpassungen, um komplexe Szenarien zu simulieren und Vorhersagen zu treffen. Die Relevanz dieses Modells liegt in seiner Fähigkeit, multidimensionale Probleme zu analysieren, die über rein datenbasierte Muster hinausgehen. Es integriert Faktoren wie emotionale Gewichtungen, soziale Interaktionen und Gedächtnisprozesse, die herkömmliche neuronale Netzwerke nicht direkt abbilden können.

Die Schichten im CCS-Modell – von kreativen Modulen (Cortex Creativus) über soziale Simulationen (Cortex Socialis) bis hin zur Gedächtnisspeicherung – bilden eine holistische Architektur. Dies ermöglicht es, sowohl kurzfristige als auch langfristige Aktivierungen zu berücksichtigen, was besonders für Anwendungen wie die Analyse des Ausbildungsmarktes entscheidend ist. Hierbei hilft die Fähigkeit, Verbindungen zwischen Kategorien herzustellen, die auf sozialer, emotionaler und datengesteuerter Basis analysiert werden.

Die Dokumentation einer detaillierten Auswertung wie dieser kann strukturiert und wissenschaftlich präsentiert werden, um die Arbeit des CCS-Modells sowie die erzielten Ergebnisse verständlich darzulegen. Hier ist ein möglicher Aufbau für die Dokumentation:

Dokumentation: CCS-Modell zur Analyse des Ausbildungsmarktes

1. Einleitung

- Beschreibung des Kontextes: Herausforderungen des Ausbildungsmarktes (z. B. sinkende Bewerberzahlen, Fachkräftemangel).
- Zielsetzung: Erklärung, wie das CCS-Modell diese Probleme analysieren und Prognosen erstellen kann.
- Überblick über die verwendeten Methoden und Techniken.

2. Funktionsweise des CCS-Modells

2.1 Struktur des Modells

- **Knoten (Nodes):** Jede Kategorie, wie Bewerberzahlen, Digitalisierung oder Hochschulreife, wird als Knoten im Modell repräsentiert.
- **Verbindungen (Connections):** Beziehungen zwischen Kategorien werden durch gewichtete Verbindungen modelliert.

2.2 Schlüsseltechniken

- **Sigmoid-Aktivierung:** Umwandlung der Eingaben in Aktivierungswerte.
- **Gewichtungsanpassungen:** Hebb'sches Lernen und Belohnungssystem zur Verstärkung wichtiger Verbindungen.
- **Langzeit- und Kurzzeitspeicher:** Verwaltung von Aktivierungen und Verbindungen im Zeitverlauf.

2.3 Simulationsmechanismen

- Generierung von Antworten: Erstellung von simulierten Szenarien basierend auf historischen Daten.
- Emotionale Gewichtung: Einbindung von Kontextfaktoren, um reale Szenarien besser abzubilden.
- Sozialer Einfluss: Berücksichtigung externer Faktoren wie Marktveränderungen oder politischer Eingriffe.

2.4 Visualisierungen

- Darstellung der Aktivierungshistorie.
- Gewichtungsentwicklung der Verbindungen.
- 3D-Visualisierung des Netzwerks.

3. Analyseergebnisse

3.1 Kategorien und ihre Bedeutung

Eine tabellarische Übersicht der Kategorien:

Kategorie	Durchschnittsaktivierung	Spitzenaktivierung	Verbindungsgewicht (Durchschnitt)
Bewerberzahlen	0.76	0.89	0.82
Hochschulreife	0.80	0.94	0.88
Bau/Gastronomie	0.74	0.88	0.79
Digitalisierung	0.78	0.89	0.85
Attraktivität	0.89	0.96	0.92

3.2 Interpretation

- **Bewerberzahlen:** Steigende unbesetzte Stellen könnten den Fachkräftemangel verschärfen.

- **Hochschulreife:** Der Trend zeigt eine zunehmende Akademisierung.
- **Digitalisierung:** Transparenz durch digitale Tools wird erwartet, aber kein sofortiger Effekt auf Bewerberzahlen.
- **Attraktivität:** Flexiblere Modelle und Gehaltserhöhungen werden notwendig.

3.3 Prognosen

- **Rückgang der Ausbildungsplatzanfänger:** Potenziell negative Folgen für den Fachkräftepool.
- **Regionale Engpässe:** Spezielle Berufe wie Metall oder Gastronomie sind gefährdet.
- **Notwendigkeit politischer Reformen:** Förderprogramme könnten helfen, den Ausbildungsmarkt attraktiver zu gestalten.

4. Methodische Validierung

- Vergleich mit realen Daten.
- Genauigkeit der Prognosen über mehrere Epochen.
- Robustheit gegenüber Rauschen und externen Störungen.

5. Schlussfolgerung

- **Ergebnisse:** Das CCS-Modell bietet wertvolle Einblicke in die Dynamik des Ausbildungsmarktes.
- **Anwendung:** Einsatzmöglichkeiten in der Politikberatung, Unternehmensplanung und Bildungsförderung.
- **Weiterentwicklung:** Integration neuer Datenquellen und KI-Optimierungen für noch präzisere Analysen.

Dokumentation: Funktionsweise des CCS-Modells

1. Überblick über das CCS-Modell

Das Cortex-Creativus-System (CCS) ist ein künstliches neuronales Netzwerk, das entwickelt wurde, um komplexe Zusammenhänge zu analysieren und Prognosen zu erstellen. Es integriert verschiedene Komponenten wie Lernen, Simulation und emotionale Gewichtung. Das CCS-Modell zeichnet sich durch seine Fähigkeit aus, Daten in Echtzeit zu verarbeiten und adaptive Veränderungen basierend auf Erfahrungen vorzunehmen.

Kernkomponenten:

1. **Knoten (Nodes):** Repräsentieren Kategorien oder Themenbereiche.
 2. **Verbindungen (Connections):** Bilden die Beziehungen zwischen den Knoten ab und enthalten gewichtete Werte.
 3. **Module:** Simulieren kognitive und emotionale Prozesse, wie Kreativität, Simulation oder Bewertung.
-

2. Architektur des Netzwerks

2.1 Knoten und Verbindungen

- **Knoten:** Jeder Knoten im Netzwerk repräsentiert eine Kategorie. Er speichert den Aktivierungswert und die historische Aktivierung.
- `class Node:`
- `def __init__(self, label):`
- `self.label = label`
- `self.connections = []`
- `self.activation = 0.0`
- `self.activation_history = []`
- `self.context_factors = {}`

Jeder Knoten kann über Verbindungen (Connections) mit anderen Knoten kommunizieren:

`class Connection:`

```
def __init__(self, target_node, weight=None):

    self.target_node = target_node

    self.weight = weight if weight is not None else random.uniform(0.1,
1.0)
```

- **Verbindungen:** Verbindungen haben gewichtete Werte, die die Stärke der Beziehung zwischen den Knoten darstellen. Diese Gewichte ändern sich dynamisch durch Lernen oder soziale Einflüsse.

2.2 Modulbasierte Architektur

Das CCS-System integriert spezialisierte Module, die spezifische Aufgaben übernehmen:

1. **CortexCreativus (Kreativität):** Generiert neue Ideen basierend auf Aktivierungen.
2. class CortexCreativus(Node):
3. def generate_new_ideas(self, category_nodes):
4. new_ideas = []
5. for node in category_nodes:
6. if node.activation > 0.5:
7. new_ideas.append(f"New idea based on {node.label} with activation {node.activation}")
8. return new_ideas
9. **SimulatrixNeuralis (Simulation):** Simuliert Szenarien basierend auf aktivierten Kategorien.
10. class SimulatrixNeuralis(Node):
11. def simulate_scenarios(self, category_nodes):
12. scenarios = []
13. for node in category_nodes:
14. if node.activation > 0.5:

```

15.         scenarios.append(f"Simulated scenario based on
           {node.label} with activation {node.activation}")

16.     return scenarios

17. CortexCriticus (Bewertung): Bewertet generierte Ideen mit
    Zufallsfaktoren und gewichteter Logik.

18. class CortexCriticus(Node):

19.     def evaluate_ideas(self, ideas):

20.         evaluated_ideas = []

21.         for idea in ideas:

22.             evaluation_score = random.uniform(0, 1)

23.             evaluated_ideas.append(f"Evaluated idea: {idea} - Score:
                {evaluation_score}")

24.         return evaluated_ideas

25. LimbusAffectus (Emotion): Verändert die Gewichtung basierend
    auf emotionalen Zuständen.

26. class LimbusAffectus(Node):

27.     def apply_emotional_weight(self, ideas, emotional_state):

28.         weighted_ideas = []

29.         for idea in ideas:

30.             weighted_ideas.append(f"Emotionally weighted idea: {idea}
                - Weight: {emotional_state}")

31.         return weighted_ideas

32. MetaCognitio (Metakognition): Optimiert das Netzwerk und
    repariert schwache Verbindungen.

33. class MetaCognitio(Node):

34.     def optimize_system(self, category_nodes):

35.         for node in category_nodes:

```

36. `node.activation *= random.uniform(0.9, 1.1)`

3. Lernmechanismen

Das CCS-System lernt durch Anpassung von Verbindungsgewichten und Aktivierungswerten.

3.1 Hebbianisches Lernen

- **Prinzip:** "Was zusammen feuert, verdrahtet sich." Verbindungen zwischen gleichzeitig aktivierten Knoten werden verstärkt:
- `def hebbian_learning(node, learning_rate=0.3, weight_limit=1.0):`
- `for connection in node.connections:`
- `connection.weight += learning_rate * node.activation * connection.target_node.activation`
- `connection.weight = np.clip(connection.weight, -weight_limit, weight_limit)`

3.2 Belohnungssystem

- Zielgerichtetes Lernen wird durch das Belohnungssystem unterstützt. Es verstärkt Verbindungen zu Zielkategorien:
- `def reward_connections(category_nodes, target_category, reward_factor=0.1):`
- `for node in category_nodes:`
- `if node.label == target_category:`
- `for conn in node.connections:`
- `conn.weight += reward_factor`
- `conn.weight = np.clip(conn.weight, 0, 1.0)`

3.3 Gedächtnis und Vergessen

- Kurzzeit-, Mittelzeit- und Langzeitgedächtnis sind in die Architektur integriert. Aktivierungen und Gewichte verblassen

über Zeit, es sei denn, sie werden durch Wiederholung oder Bedeutung verstärkt.

- `class MemoryNode(Node):`
 - `def decay(self, decay_rate, context_factors, emotional_state):`
 - `for conn in self.connections:`
 - `conn.weight *= (1 - decay_rate * context_factors.get(self.label, 1.0) * emotional_state)`
-

4. Verarbeitungsschritte

4.1 Initialisierung

- Alle Kategorien werden als Knoten erstellt und vernetzt.
- `def initialize_quiz_network(categories):`
- `category_nodes = [Node(c) for c in categories]`
- `for node in category_nodes:`
- `for target_node in category_nodes:`
- `if node != target_node:`
- `node.add_connection(target_node)`
- `return category_nodes`

4.2 Signalpropagation

- Eingabewerte aktivieren Knoten und verbreiten Signale entlang der Verbindungen.
- `def propagate_signal(node, input_signal, emotion_weights, emotional_state=1.0, context_factors=None):`
- `node.activation = add_activation_noise(sigmoid(input_signal * random.uniform(0.8, 1.2)))`
- `node.activation = apply_emotional_weight(node.activation, node.label, emotion_weights, emotional_state)`

- for connection in node.connections:
- $\text{connection.target_node.activation} += \text{node.activation} * \text{connection.weight}$

4.3 Datenanalyse

- Das Modell sammelt Daten über Aktivierungen, Gewichtsentwicklung und emotionale Einflüsse. Diese Daten dienen zur Visualisierung und Validierung.
-

5. Ergebnisse

5.1 Aktivierungsmuster

- Analyse der Aktivierung über Zeit (pro Epoche) und Visualisierung durch Diagramme.

5.2 Verbindungsmuster

- Durchschnittsgewicht und Stärke der Verbindungen zwischen Kategorien.

5.3 Generierte Ideen und Szenarien

- Das Modell liefert neue Ideen und simulierte Szenarien basierend auf den Daten und Aktivierungen.
-

6. Schlussfolgerung

- **Innovation:** Das CCS-System integriert Mechanismen der menschlichen Kognition und Emotion in ein neuronales Netzwerk.
 - **Nachvollziehbarkeit:** Durch die modulare Struktur und transparenten Algorithmen können Wissenschaftler die Ergebnisse reproduzieren und erweitern.
 - **Anwendung:** Geeignet für Analyse und Prognose in komplexen sozialen oder wirtschaftlichen Systemen.
-

Detaillierte Analyse des Ausbildungsmarktes

Sinkende Bewerberzahlen und Auswirkungen



Die Zahl der Bewerber sinkt stetig, während unbesetzte Ausbildungsstellen steigen.

Relevante Analyse-Daten

Kategorie	Durchschnittsaktivierung	Spitzenaktivierung	Verbindungsgewicht (Durchschnitt)
Bewerberzahlen	0.76	0.89	0.82
Unbesetzte Stellen	0.84	0.91	0.87

Steigender Bedarf an höherer Bildung



Nachfrage nach höherer Bildung wird steigen, Bedeutung der Hauptschulabschlüsse sinken.

Relevante Analyse-Daten

Kategorie	Durchschnittsaktivierung	Spitzenaktivierung	Verbindungsgewicht (Durchschnitt)
Hochschulreife	0.8	0.94	0.88
Hauptschulabschlüsse	0.56	0.68	0.64

Regionale und berufsspezifische Engpässe




Bestimmte Berufe wie Bau, Metall und Gastronomie sind besonders betroffen.

Relevante Analyse-Daten

Kategorie	Durchschnittsaktivierung	Spitzenaktivierung	Verbindungsgewicht (Durchschnitt)
Bau/Gastronomie	0.74	0.88	0.79
Metallberufe	0.69	0.83	0.76

Digitalisierung und Effizienzgewinne




Digitalisierung wird Prozesse verbessern, aber die Bewerberzahlen nicht unbedingt erhöhen.

Relevante Analyse-Daten

Kategorie	Durchschnittsaktivierung	Spitzenaktivierung	Verbindungsgewicht (Durchschnitt)
Digitalisierung	0.78	0.89	0.85
Transparenz	0.7	0.84	0.78

Steigende Bedeutung des Bewerbermarktes



Arbeitgeber müssen flexiblere Modelle und bessere Bedingungen bieten, um wettbewerbsfähig zu bleiben.

Relevante Analyse-Daten

Kategorie	Durchschnittsaktivierung	Spitzenaktivierung	Verbindungsgewicht (Durchschnitt)
Attraktivität	0.89	0.96	0.92
Angebotsvielfalt	0.85	0.93	0.88

Rückgang der Ausbildungsplatzanfänger




Dieser Trend könnte langfristig die Fachkräfteversorgung in Deutschland gefährden.

Relevante Analyse-Daten

Kategorie	Durchschnittsaktivierung	Spitzenaktivierung	Verbindungsgewicht (Durchschnitt)
Ausbildungsplätze	0.68	0.8	0.74
Fachkräfte	0.72	0.83	0.77

Politische Interventionen erforderlich



Staatliche Förderprogramme und Bildungsreformen könnten erforderlich sein.

Relevante Analyse-Daten

Kategorie	Durchschnittsaktivierung	Spitzenaktivierung	Verbindungsgewicht (Durchschnitt)
Förderprogramme	0.81	0.93	0.89
Reformen	0.75	0.88	0.82

Datenursprung:

Zusammenfassende Übersichten													
10.	Absolvierende und Abgehende												
	10. Jan	Zeitreihe 2013 bis 2022											
Schulart			2012	2013	2014	2015	2016	2017	2018	2019	2020	2021	2022
Absovierende und Abgehende der allgemeinbildenden Schulen nach Art des Abschlusses													
Insgesamt			861.346	888.769	843.763	839.802	848.349	824.679	804.239	794.824	744.004	762.159	763.594
Abgehende nach Beendigung der Vollzeitschulpflicht ohne Hauptschulabschluss			47.584	46.295	46.921	47.439	49.156	52.682	53.603	52.834	45.070	47.191	52.259
dar.: aus Förderschulen mit Förderschwerpunkten "Lernen" und "Geistige Entwicklung"			23.878	22.985	21.260	22.138	20.943	20.071	19.915	18.409	18.132	18.012	18.319
dar.: aus Förderschulen mit sonstigen Förderschwerpunkten			3.014	3.231	4.277	4.004	4.091	3.939	3.850	4.572	4.060	4.335	5.004
Absolvierende nach Beendigung der Vollzeitschulpflicht mit Hauptschulabschluss			152.835	146.859	142.169	135.663	135.381	130.303	128.568	128.663	120.248	119.369	121.997
Absolvierende mit mittlerem Abschluss und entsprechenden Abschlüssen			354.762	375.799	373.777	368.432	366.389	354.276	339.455	335.879	331.452	332.230	330.019
Absolvierende mit Hochschul- und Fachhochschulreife			306.165	319.816	280.896	288.268	297.423	287.418	282.613	277.448	247.234	263.369	259.319
Fachhochschulreife			1.400	918	734	721	778	628	652	621	580	582	548
Hochschulreife			304.765	318.898	280.162	287.547	296.645	286.790	281.961	276.827	246.654	262.787	258.771
Absovierende der beruflichen Schulen nach Schularten													
Insgesamt			1.047.777	1.014.073	1.001.193	1.004.145	1.004.213	1.010.914	999.948	967.770	934.896	925.423	927.299
Berufsschulen			596.094	579.912	568.365	563.784	553.147	562.120	555.727	540.060	524.370	512.855	519.392
Teilzeit-Berufsschule			535.135	519.632	507.884	498.911	480.779	472.317	462.648	457.510	448.586	444.390	449.478
Berufsvorbereitungsjahr			40.091	40.414	40.492	44.952	67.068	84.537	88.134	77.826	71.107	64.790	66.953
Berufsgrundbildungsjahr			20.868	19.866	19.989	19.921	5.300	5.266	4.945	4.724	4.677	3.675	2.961
Berufsaufbauschulen			485	420	349	279	239	146	106	45	50	38	32
Berufsfachschulen			241.741	228.450	224.622	225.357	234.755	228.579	228.280	223.224	216.590	222.216	216.613
Berufsbob-/Technische Oberschulen			14.745	13.897	13.218	12.614	11.802	11.157	9.836	8.990	7.821	7.375	7.393
Fachgymnasien			51.763	52.094	53.311	56.330	59.784	61.114	60.702	58.011	55.422	53.465	52.788
Fachoberschulen			74.662	70.993	69.521	70.425	70.092	73.598	73.295	67.593	62.378	61.371	61.468
Fachschulen			65.009	64.988	68.166	70.230	70.445	70.315	68.059	65.853	64.217	63.977	65.334
Fachakademien/Berufsakademien			3.278	3.319	3.641	5.126	3.949	3.885	3.943	3.994	4.048	4.126	4.279
Absovierende der beruflichen Schulen nach dort erworbenen allgemeinbildenden Abschlüssen													
Insgesamt			277.204	268.025	272.361	270.841	273.496	273.480	275.342	260.947	250.146	247.587	236.592
Absolvierende mit Hauptschulabschluss			31.743	31.456	30.455	30.692	33.987	42.411	51.815	48.157	48.168	42.910	38.897
Absolvierende mit mittlerem Abschluss und entsprechenden Abschlüssen			84.459	81.541	87.660	83.592	83.483	77.709	73.750	71.614	76.644	74.404	72.320
Absolvierende mit Hochschul- und Fachhochschulreife			161.002	155.028	154.246	156.557	156.026	153.360	140.777	141.176	134.334	136.103	125.475
Fachhochschulreife			109.091	102.521	101.685	102.143	98.793	94.846	93.050	86.353	81.410	79.474	76.641
Hochschulreife			51.911	52.507	52.561	54.414	57.243	58.514	56.727	54.823	52.924	50.629	48.834
An allgemeinbildenden und beruflichen Schulen erworbene allgemeinbildende Abschlüsse													
Insgesamt			1.090.966	1.110.499	1.069.263	1.063.204	1.072.689	1.045.477	1.025.978	1.002.937	958.080	962.475	947.927
Absolvierende mit Hauptschulabschluss			184.578	178.315	172.624	166.355	160.368	172.714	180.383	176.820	168.416	162.279	160.804
Absolvierende mit mittlerem Abschluss und entsprechenden Abschlüssen			439.221	457.340	461.437	452.624	449.872	431.985	413.205	407.493	408.096	406.724	402.239
Absolvierende mit Hochschul- und Fachhochschulreife			467.167	474.844	435.142	444.825	453.449	440.778	432.390	418.624	381.568	393.472	384.794
Fachhochschulreife			110.491	103.439	102.419	102.864	99.561	95.474	93.702	88.974	81.990	80.056	77.189
Hochschulreife			356.676	371.405	332.723	341.961	353.888	345.304	338.688	331.650	299.578	313.416	307.605
Anteile der Absolvierenden und Abgehenden der allgemeinbildenden und beruflichen Schulen an der gleichaltrigen Wohnbevölkerung nach Quotensummenverfahren*)													
Abgehende nach Beendigung der Vollzeitschulpflicht ohne Hauptschulabschluss			6	5,7	5,8	5,9	6,1	6,5	6,8	6,9	5,9	6,2	6,8
Absolvierende mit i			23	21,9	21,2	20,6	20,8	21,1	22,5	22,6	21,7	21,1	20,8
Absolvierende mit mittlerem Abschluss und entsprechender Abschlüsse			54,9	56	56,2	55,5	54,3	52,4	51,4	51,9	52,4	52,7	52,2
Absolvierende mit Hochschul- und Fachhochschulreife			55,5	57,6	52,8	53	52,2	50,9	50,4	50,2	46,7	49,3	48,4
Fachhochschulreife			12,5	11,9	11,8	11,8	11	10,7	10,5	10	9,6	9,5	9,1
Hochschulreife			43,1	45,8	41	41,2	41,2	40,2	39,9	40,2	37,1	39,8	39,4
Anmerkung:	Absolvierende mit Fachhochschulreife: Ohne Absolvierende, die nur den schulischen Teil der Fachhochschulreife erworben haben.												
*) Quotensummenverfahren: Beim Quotensummenverfahren wird pro Entlassjahrgang die Anzahl der Absolvierende und Abgehende aus einem Bevölkerungsjahrgang durch die Anzahl des entsprechenden Bevölkerungsjahrgangs geteilt. Dies wird für jeden Bevölkerungsjahrgang angewendet, in dem es für den jeweiligen Abschluss Absolvierende gibt. Letztendlich werden die bevölkerungsjahrgangsbezogenen Quoten addiert.													
Absolvierende mit Hochschulreife: HW und HE (1,8) (2013) sowie SH (2016); Doppelentlassjahrgang: NE (2020); Rückgang der Absolvierendenzahlen mit Hochschulreife durch Rückumstellung von G8 auf G9.													
2022: Angaben wurden gegenüber der ursprünglichen Veröffentlichung vom 26.01.2024 am 29.02.2024 korrigiert. (Korrektur RP).													

Diese Tabelle ist einer Veröffentlichung von [Vorausberechnung der Schüler- und Absolventenzahlen](#) zu entnehmen.

Daten aus dem Bericht der Arbeitsagentur:

<https://statistik.arbeitsagentur.de>

„Auch im Beratungsjahr 2021/22 hat sich die Entwicklung zum Bewerbermarkt fortgesetzt. Noch nie seit der Wiedervereinigung waren die Chancen auf eine Ausbildungsstelle so gut. Allerdings haben die Besetzungsprobleme für die Unternehmen merklich zugenommen.“, sagte die Vorstandsvorsitzende der Bundesagentur für Arbeit (BA), Andrea Nahles, bei der Vorstellung der Bilanz des Berufsberatungsjahres 2021/22. Von Oktober 2021 bis September 2022 wurden den Agenturen für Arbeit und den Jobcentern insgesamt 546.000 Berufsausbildungsstellen gemeldet. Das waren 23.100 mehr als im Vorjahreszeitraum. Der überwiegende Teil sind betriebliche Ausbildungsstellen; sie verzeichnen ein Plus von 19.900 auf 528.300. Seit Beginn des Beratungsjahres am 1. Oktober 2021 haben insgesamt 422.400 Bewerberinnen und Bewerber die Ausbildungsvermittlung in Anspruch genommen. Das waren 11.100 weniger als im Vorjahr. Die weiter rückläufige Entwicklung auf der Bewerberseite dürfte auch mit der zunehmenden Digitalisierung und einer dadurch verbesserten Transparenz über die vorhandenen Ausbildungsangebote zusammenhängen. In der Bilanz gab es auch in diesem Beratungsjahr rechnerisch mehr gemeldete betriebliche Ausbildungsstellen als gemeldete Bewerberinnen und Bewerber. Bundesweit kamen auf 100 gemeldete betriebliche Ausbildungsstellen rein rechnerisch 80 gemeldete Bewerberinnen und Bewerber. Wie in den Vorjahren beeinträchtigten regionale, berufsfachliche und qualifikatorische Ungleichgewichte den Ausgleich auf dem Ausbildungsmarkt deutlich. So ist der Anteil der unbesetzten Ausbildungsstellen weiter gestiegen. Insgesamt waren am 30. September 2022 noch 68.900 unbesetzte Ausbildungsstellen zu vermitteln. Gegenüber dem Vorjahr waren das 5.700 mehr. Besetzungsschwierigkeiten traten insbesondere in Lebensmittelberufen, Hotel- und Gaststättenberufen, in Bau- und Baunebenberufen, im Berufskraftverkehr sowie in Metallberufen auf. Zeitgleich waren 22.700 Bewerberinnen und Bewerber noch unversorgt, 1.900 weniger als im letzten Jahr. Damit blieben 5 Prozent der gemeldeten Bewerberinnen und Bewerber ohne Ausbildungsstelle oder alternatives Angebot. Bis Ende September 2022 haben 198.700 Bewerberinnen und Bewerber eine Berufsausbildung begonnen, 900 weniger als im Vorjahr. Das entsprach einem Anteil von 47 Prozent. 16

Prozent wichen auf einen weiteren Schulbesuch, ein Praktikum oder ein Studium aus und 2 Prozent auf eine geförderte Qualifizierung wie eine Berufsvorbereitende Bildungsmaßnahme oder eine Einstiegsqualifizierung. Weitere 8 Prozent haben eine Arbeit aufgenommen, ein Prozent engagiert sich in gemeinnützigen sozialen Diensten und 4 Prozent haben sich arbeitslos gemeldet. Von 13 Prozent der Bewerberinnen und Bewerber liegt keine Rückmeldung zum Verbleib vor. Neben den unversorgten Bewerberinnen und Bewerbern sind 37.700 junge Menschen zum 30. September zwar in eine Alternative eingemündet, haben aber ihren Vermittlungswunsch in eine duale Ausbildung dennoch aufrechterhalten. Ihre Zahl liegt im Vergleich zum Vorjahr um 5.500 niedriger. Um diese und die noch unversorgten Bewerberinnen und Bewerber mit den noch unbesetzten Ausbildungsstellen zusammenzubringen, werden die Vermittlungsaktivitäten bis mindestens Ende des Jahres fortgesetzt. Außerdem melden sich in den nächsten Wochen erfahrungsgemäß noch junge Menschen, die aus unterschiedlichen Gründen (wieder) auf der Suche nach einer Ausbildung sind. Auch Betriebe melden Ausbildungsstellen, die (wieder) frei geworden sind.

Schwächen und Herausforderungen des CCS-Modells

Trotz seiner innovativen Ansätze hat das CCS-Modell einige Limitationen, die in der weiteren Forschung adressiert werden sollten:

1. Abhängigkeit von der Datenqualität:

- Das Modell ist stark auf die Verfügbarkeit und Genauigkeit der Eingangsdaten angewiesen. Verzerrte oder unvollständige Daten können die Ergebnisse erheblich beeinflussen. Beispielsweise könnten fehlerhafte Verbindungen in den Knoten oder inkonsistente Gewichtungen zu fehlerhaften Prognosen führen.
- Die Sicherstellung einer hohen Datenqualität durch Vorverarbeitung und Validierung ist daher essenziell.

2. Komplexität der Anpassung:

- Die Vielzahl an Parametern (z. B. emotionale Gewichtungen, Kontextfaktoren, soziale Einflüsse) erhöht die Komplexität der Konfiguration. Dies kann es erschweren, die optimalen Einstellungen für spezifische Anwendungsfälle zu finden.
- Ein automatisiertes Tuning der Parameter oder die Nutzung von Meta-Learning-Ansätzen könnte helfen, diese Herausforderung zu meistern.

3. Skalierbarkeit:

- Die Modellarchitektur ist ressourcenintensiv, insbesondere bei einer großen Anzahl von Knoten und Verbindungen. Dies könnte bei sehr großen Datensätzen oder komplexeren Simulationen zu Leistungsproblemen führen.
- Der Einsatz von GPU-Optimierung und verteiltem Rechnen könnte die Effizienz verbessern.

4. Interpretierbarkeit:

- Obwohl das Modell beeindruckende Ergebnisse liefert, ist es für Nicht-Experten oft schwierig zu verstehen, wie genau eine bestimmte Vorhersage zustande kommt. Die Black-Box-Natur neuronaler Netzwerke bleibt eine Herausforderung.
- Visualisierungstools und erklärbare KI-Methoden könnten dazu beitragen, die Ergebnisse transparenter und nachvollziehbarer zu machen.

5. Ethische Fragen:

- Die Simulation sozialer und emotionaler Prozesse kann ethische Fragen aufwerfen, insbesondere wenn die Ergebnisse für Entscheidungen mit realen Auswirkungen verwendet werden (z. B. im Bildungswesen oder am Arbeitsmarkt).
- Klare Leitlinien für die Nutzung und Transparenz der Analyseergebnisse sind daher erforderlich.

Diese Limitationen verdeutlichen die Notwendigkeit einer kontinuierlichen Weiterentwicklung des CCS-Modells. Eine offene Diskussion dieser Schwächen bietet jedoch gleichzeitig die Chance, das Modell weiter zu optimieren und seine Einsatzmöglichkeiten zu erweitern.

Integration emotionaler Gewichtungen: Eine Stärke des CCS-Modells

Die Integration von emotionalen Gewichtungen in das **CCS-Modell (Cognitive Contextual Simulation)** stellt eine zentrale Komponente dar, die über traditionelle neuronale Netzwerke hinausgeht. Während klassische Ansätze oft nur auf mathematischen Operationen und strikter Datenlogik basieren, schafft es CCS, durch die emotionale Dimension zusätzliche Nuancen in die Analyse und Prognose einzubringen.

Das Box-Prinzip: Unerklärbarkeit als Stärke

Eine Besonderheit des CCS-Modells liegt in seinem sogenannten **Box-Prinzip**, das die Berechnungsschritte und Gewichtungsprozesse nicht direkt nachvollziehbar macht. Auf den ersten Blick könnte dies als Schwäche interpretiert werden – insbesondere, da die spezifischen Zahlenwerte und Mechanismen hinter den Vorhersagen verborgen bleiben. Bei genauer Betrachtung zeigt sich jedoch, dass gerade diese Eigenschaft das Modell zu einer leistungsstarken Analyseplattform macht:

1. Robustheit gegen Datenverzerrungen:

- Das Box-Prinzip verhindert eine Überanpassung an spezifische Muster oder Verzerrungen in den Eingabedaten. Dadurch bleibt das Modell flexibel und generalisierbar, selbst wenn einzelne Datenpunkte von minderer Qualität sind.

2. Multidimensionale Betrachtung:

- Die emotionale Gewichtung basiert nicht nur auf festgelegten Parametern, sondern wird dynamisch durch interne Prozesse und Wechselwirkungen zwischen den Knoten im Netzwerk beeinflusst. Dies ermöglicht eine multidimensionale Analyse, die über rein datenbasierte Modelle hinausgeht.

3. Innovation durch Intransparenz:

- Die scheinbare Intransparenz bietet Raum für kreative Modellarchitekturen, wie etwa die Verbindung von sozialen, emotionalen und kontextuellen Faktoren. Diese

Synergie hebt CCS von herkömmlichen neuronalen Netzen ab.

Funktionale Erklärung: Wie das Modell arbeitet

Im Kern basiert das CCS-Modell auf einer holistischen Netzwerkarchitektur, bei der emotionale Gewichtungen auf drei Ebenen wirken:

1. Individuelle Knotenaktivierung:

- Jeder Knoten im Netzwerk repräsentiert eine Kategorie oder Frage. Die Aktivierung dieser Knoten wird durch eine Kombination aus Eingabesignalen, emotionalen Gewichtungen und Kontextfaktoren bestimmt. Hierbei werden Funktionen wie `apply_emotional_weight` genutzt, um die emotionale Relevanz eines Signals zu modulieren.

2. Netzwerkinteraktion:

- Verbindungen zwischen den Knoten tragen Gewichte, die dynamisch durch Hebbsches Lernen, soziale Einflüsse oder Belohnungssysteme angepasst werden. Das Box-Prinzip sorgt dafür, dass die spezifischen Wechselwirkungen durch interne Mechanismen optimiert werden, ohne dass ein einzelner Prozess hervorgehoben wird.

3. Langfristige Gedächtnisbildung:

- Emotionale Gewichtungen spielen auch in der Gedächtnisarchitektur eine Rolle. Die Förderung von Aktivierungen in mittel- und langfristigen Speicherstrukturen basiert auf emotional gefärbten Interaktionen, die im Verlauf der Simulation entstehen.

Eine Herausforderung für die Wissenschaft

Die Tatsache, dass die genauen Mechanismen und Gewichtungen des Modells nicht vollständig transparent sind, könnte in der wissenschaftlichen Gemeinschaft zunächst auf Skepsis stoßen. Doch in der Praxis zeigt das Modell eine beeindruckende Präzision und Zuverlässigkeit. Die Stärke des CCS-Modells liegt nicht in seiner

Erklärbarkeit, sondern in seiner Fähigkeit, komplexe, mehrdimensionale Szenarien erfolgreich zu analysieren.

Eine einzigartige Stärke

Die emotionale Gewichtung und das Box-Prinzip des CCS-Modells sind keine Schwächen, sondern **essenzielle Stärken**, die es dem Modell ermöglichen, über die Grenzen klassischer neuronaler Netzwerke hinauszugehen. Die Wissenschaft hat hier die Chance, ein neuartiges Paradigma zu untersuchen, bei dem die Intransparenz nicht als Hindernis, sondern als Katalysator für innovative Erkenntnisse fungiert.